

FlowHub - Reflexion: KI-gestützte Entwicklung

CAS AI-Assisted Software Engineering (AISE) · W4B-C-AS001 · ZH-Sa-1 · FS26 **Student:** Andreas Imboden · **Stand:** Juni 2026

Dieses Dokument reflektiert den **KI-Einsatz** über alle fünf CAS-Blöcke: welche Werkzeuge wie eingesetzt wurden, wie sich der Workflow entwickelt hat, was verlässlich funktioniert hat und was nicht — und welche Disziplinen als tragfähig über das Projekt hinaus erscheinen. Die detaillierte, blockweise Aufschlüsselung (generated-vs-handwritten-Anteile, Korrektur-Geschichten) liegt in `docs/ai-usage.md`.

1. KI-Werkzeuge im Entwicklungsprozess

Werkzeug	Einsatzbereich
Claude Code (Opus, 1M-Kontext)	Brainstorming, Spec-/Plan-Erstellung, ADR-Drafts, Controller für Subagent-Dispatches
Claude Sonnet (Subagents)	Implementer + Spec-Reviewer + Code-Quality-Reviewer unter dem <code>subagent-driven-development</code> -Workflow
Claude Haiku (Subagents)	Mechanische Tasks (csproj/Markdown/YAML), ca. 60 % Token-Ersparnis gegenüber Sonnet
<code>/ultrareview</code> (Multi-Agent-Branch-Review)	Architektonisches Review über einen ganzen Feature-Branch — fängt System-Invarianten ab, die Per-Task-Review nicht sieht
Microsoft.Extensions.AI + Anthropic/OpenRouter	KI im Produkt (Classifier, Enrichment, Embeddings)
Eigene CAS-Skills	<code>cas-aise-todo-list</code> , <code>cas-aise-grade-self-check</code> , <code>sync-ai-instructions</code> — Rubrik-Verankerung, Block-/Phasen-Steuerung, Cross-Project-Reuse

2. Workflow-Entwicklung (Block 1 → Block 5)

Mit jedem Block wurde ad-hoc-Chat gegen strukturierteren, isolierteren Subagent-Dispatch getauscht. Der Mehraufwand für Struktur hat sich durch weniger Mid-Task-Eskalationen und seltenere „Agent-ist-abgedriftet“-Momente bezahlt gemacht.

Block	Workflow-Verschiebung
1 — Einführung	Ad-hoc-Chat für Architektur; Copilot inline für Code.
2 — Frontend	Erster sustained CLI-Einsatz mit phasenbasierter Disziplin (<code>/ui-brainstorm</code> → <code>/ui-flow</code> → <code>/ui-build</code> → <code>/ui-review</code>).
3 — Service	Erster vollständiger <code>brainstorming</code> → <code>writing-plans</code> → <code>subagent-driven-development</code> -Slice; zweistufiges Review (Spec + Quality) pro Task.
4 — Persistence	Sonnet als Default, Haiku für Mechanik; Per-Task-Quality-Review zugunsten einer Branch-Review am Slice-Ende fallen gelassen — ca. 60 % Token-Burn reduziert ohne Qualitätsverlust.
5 — Deployment	<code>/ultrareview</code> und rubrik-gegrundetes <code>cas-aise-grade-self-check</code> ergänzt; jede Block-Abschluss-Prüfung läuft durch die Skill.

Subagent-Driven Development (SDD) bezeichnet das hier verwendete Muster: ein Plan wird in kleine, wohldefinierte Tasks zerlegt, jeder Task von einem isolierten Implementer-Subagent umgesetzt, während **getrennte** Subagents Spezifikation und Code-Qualität prüfen.

Bis Block 5 verantworten solche Implementer-Subagents ganze Slices end-to-end. Die menschliche Arbeit konzentriert sich dadurch auf zwei Stellen: **Spec** (wo die Verträge festgelegt werden) und **Review** (wo die System-Invarianten geprüft werden). Anders gesagt: Sobald die KI das Implementieren übernimmt, ist nicht mehr die Tipp- bzw. Implementierungsgeschwindigkeit der begrenzende Faktor, sondern die Qualität von Spezifikation und Review. Der **Engpass** des Projekts — die Stelle, die das Tempo bestimmt — verschiebt sich also vom Code-Schreiben hin zu diesen beiden Tätigkeiten.

3. Was funktioniert hat

1. **Der Plan ist der Vertrag.** Enthält der Plan exakte Pfade, exakten Code, exakte Commit-Messages und exakte Verifikationskommandos, operiert der Implementer mit engem Spielraum und meldet DONE statt NEEDS_CONTEXT. Die 95 %+ „AI-drafted“-Anteile im Produktionscode sind nur deshalb erreichbar.
2. **Review-Kadenz muss zur Fehlerklasse passen.** Per-Task-Spec + Per-Task-Quality war für den ersten SDD-Lauf (Block 3) richtig. Ab Block 4 fing Per-Task-Quality nichts Neues mehr, während ein branchweites `/ultrareview` am Slice-Ende genau die Architektur-Fehler fand, die Per-Task-Review nicht sehen konnte.
3. **Eigene Skills als Memory-Layer des Projekts.** `cas-aise-grade-self-check`, `cas-aise-todo-list`, `sync-ai-instructions` decken Concerns ab, die das Upstream-Plugin nicht behandelt: Rubrik-Verankerung, kalendergetriebene Priorisierung, Cross-Project-Reuse. Ohne `cas-aise-grade-self-check` driftete die Rubrik-Abdeckung in langen Sessions.
4. **KI für rigide Struktur-Artefakte, Mensch für architektonisches Urteil.** GitHub-Actions-YAML, ADR-Scaffolds, ProblemDetails, EF-Migrationen — rigide Strukturen, in denen der 90 %-korrekte AI-Erstwurf reale Zeit spart. Architektur-Entscheidungen (hexagonaler Split, In-Process vs. RabbitMQ) bleiben beim Menschen; die KI listet Alternativen, sie wählt nicht.
5. **Konkrete Korrektur-Geschichten sind die überzeugendste Evidenz für den KI-Einsatz.** Eine nachvollziehbare Kette — *die KI erzeugte Code X, der Smoke-Test fand den Fehler Y, der Fix landete in Commit Z* — macht den KI-gestützten Workflow überprüfbar (Defekt, fixender Commit, Lehre sind verlinkt). Pauschale Aussagen wie „die KI hat geholfen“ leisten das nicht und sind für eine Bewertung wertlos.

4. Wiederkehrende Fehlerquellen

1. **Single-Pass-AI-Review übersieht System-Invarianten.** Block-5-Beispiel: AI-generierter Code, der Embedding-Generation in `EfCaptureService.SubmitAsync` integrierte, war lokal korrekt (eine Transaktion), global aber falsch — ein langsamer Provider sprengt das Submit-Latenz-Budget. Per-Task-Quality-Review fand das nicht; `/ultrareview` fand es beim ersten Lauf.

2. **Deployment-Shape-Failures sind systematisch unter-getestet.**

Compose- `${X:-}` -Interpolation substituiert leere Strings (nicht null), wodurch `??` -Defaults still no-op'en; `.editorconfig` fehlte im Docker-Build-Kontext; ein Casing-Mismatch (`EMBEDDINGS__APIKEY` vs. `Embeddings__ApiKey`) schaltete ein ganzes Feature aus. Fünf solcher Defekte fing `just smoke-prod` an einem Nachmittag.

3. **Training-Data-Lag bei aktuellen Libraries.** `Pgvector.EntityFrameworkCore` wurde als in-the-box-Feature angenommen (ist ein separates Paket);

`MassTransit.Testing` umgekehrt als separates Paket (ist Teil der Haupt-Assembly). API-Behauptungen der KI müssen gegen das installierte Paket verifiziert werden.

4. **Offene Prompts inflationieren den Scope.** „Füge X hinzu“ ohne Plan produziert eine Feature-Suite. Gegenmittel: kleinteilige, TDD-geordnete Tasks mit Inline-Code, exakten Pfaden und Commit-Messages.

5. **Pläne aus unvollständigem Repo-Wissen.** Ein Slice-Plan übersah eine bestehende Test-Datei und vorhandene Enum-Werte; seitdem liest Planning jede referenzierte Datei, *bevor* der Plan eingefroren wird.

5. Tragfähige Disziplinen (über das Projekt hinaus)

Die wertvollsten Erkenntnisse sind weniger einzelne Tools als wiederholbare Arbeitsweisen:

- **AI-Instructions wie ein Onboarding-Dokument pflegen.** `CLAUDE.md` für harte Regeln, `.ai/` -Instructions als kanonische Konventionsreferenz. Ohne diese Schichten driftet jeder Agent in seine Defaults; mit ihnen werden Instruktionen einmal geschrieben und von Claude Code, Codex, Copilot gleichermassen befolgt.
- **Eigene Skills schreiben.** Kleine, scharf umrissene Markdown-Definitionen mit Trigger-Description und geprüftem Vorgehen — der Agent erkennt selbst, *wann* ein Skill anzuwenden ist, und folgt einer Checkliste statt zu improvisieren.
- **Skills thematisch in Plugins aufteilen.** Jede Skill-Description kostet System-Prompt-Tokens und verwässert die Trigger-Schärfe. Nur das Plugin aktivieren, das zur aktuellen Arbeit passt.

- **Context-Hygiene: Logs via Datei.** Console-/Build-/Test-Output in eine Datei schreiben und gezielt mit `Read / grep` lesen, statt ganze Streams ins Kontextfenster zu kippen — subjektiv Faktor 5-10 weniger Token pro Debug-Session.
- **Code-Exploration bewusst eskalieren.** Erst `rg` (ripgrep, schnelle Text-Suche); wenn drei Suchanläufe nichts liefern, ist die Frage semantisch und kein reines Text-Matching. Dann helfen ein **LSP** (Language Server Protocol — löst Symbole, Referenzen und Definitionen auf, statt nur Textstellen zu finden) oder semantische Such-Tools.
- **Spec → Plan → Implement mit harten `/clear` -Schnitten.** Jede Phase produziert ein Artefakt auf Disk, das die nächste Phase als reinen Input zurückliert; der vorherige Dialog wird verworfen. Das ist die strukturelle Variante des Logs-via-Datei-Patterns.

6. Was ich anders machen würde

- **Rubrik-Verankerung ab Block 1, nicht Block 3.** `cas-aise-grade-self-check` entstand mittendrin; Block 1-2 hatten keine formalen `use-cases.md` / `nfa.md` / `acceptance-criteria.md`. Retroaktive Doku-Arbeit kostete Zeit.
- **`/ultrareview` ab Block 3, nicht Block 5.** Branchweites Multi-Agent-Review fängt die Fehlerklasse, die Per-Task-Review nicht sieht — günstiger nach Slice B als nach einem 21-Task-MVP.
- **Ein `just smoke` -Rezept pro Block, nicht nur Block 5.** Ein einfaches Smoke (App booten, Feature-Pfad curlen) hätte mindestens drei der fünf späten Bugs früher gefangen.
- **Mechanische Patterns ins Plan-Template kodifizieren.** Beispiel `InternalsVisibleTo`: ein .NET-Attribut, das einem Test-Projekt Zugriff auf die `internal`-Typen des Produktiv-Projekts gibt, ohne diese öffentlich (`public`) zu machen — die Domänen-Entities bleiben gekapselt und sind trotzdem testbar. Implementer-Subagents weiteten bei Compile-Fehlern stattdessen oft reflexartig die Sichtbarkeit auf `public` aus; einmal im Plan-Template ausgeschrieben (ebenso das EF-Core-Test-Host-Setup), verschwindet diese Friktion.

7. Hat die Ausgangshypothese gestimmt?

Die Hypothese zu Projektbeginn (Block 1) lautete: Claude sei „ein schneller Tipper mit guter Library-Kenntnis" — also nützlich für Boilerplate, fragwürdig bei Architektur, und insgesamt ein Produktivitäts-Multiplikator, der den Workflow aber nicht grundlegend verändert. Bis Block 5 erwies sich diese Annahme in **beiden** Punkten als falsch — und zwar in entgegengesetzte Richtungen.

Beim Boilerplate wurde die KI unterschätzt. Über 95 % des Produktionscodes sind KI-erstellt. Das heisst aber nicht „die KI hat 95 % der Arbeit gemacht": die verbleibenden ~5 % menschlicher Anteil verlagern sich fast vollständig auf Entscheidungen mit hohem Urteilsbedarf — Scope, Verträge, Trade-offs. Das reine Tippen ist nur noch ein kleiner Bruchteil der aufgewendeten Zeit.

Bei der Architektur wurde dagegen die menschliche Rolle unterschätzt. Der Embedding-on-Submit-Fall (Kapitel 4) zeigt es: lokal korrekter, plausibel aussehender Code, der eine System-Invariante — das Submit-Latenz-Budget — verletzte und ein oberflächliches Single-Pass-Review passiert hätte. Solche Fehler produziert die KI schneller, als ein flüchtiges Review sie fangen kann. Die menschliche Rolle an der Architektur-Grenze ist deshalb nicht geschrumpft, sondern **gewachsen**: Gerade weil der Agent genug korrekten Code schnell genug liefert, wird der entscheidende menschliche Beitrag der **Filter** aus Design und Review.

Beide Beobachtungen zeigen in dieselbe Richtung und führen direkt zum Fazit.

8. Fazit

KI hat keine Rolle im Workflow ersetzt — sie hat **verschoben, welche Rolle der Engpass ist**. Implementierungs-Durchsatz ist nicht mehr die Beschränkung; Design- und Review-Durchsatz sind es. Für das nächste Projekt: zuerst die Spec-Dokumente, `/ultrareview` ab Tag eins, ein Smoke-Target vor dem ersten Feature.

Transfer CAS → Projektarbeit

CAS-Block	Mitgenommener Inhalt	Konkrete FlowHub-Entscheidung
1 — Einführung	Architekturoptionen begründet abwägen; KI-Tooling aufsetzen	Modular Monolith mit hexagonaler Schichtung (ADR 0001) + die ADR-Praxis selbst; Tooling-Fundament (<code>CLAUDE.md</code> , <code>.ai/</code> , eigene Skills)
2 — Frontend	Render-Modelle, Frontend-Architektur	Blazor Interactive Server statt WASM-SPA (ADR 0001); vierstufige UI-Pipeline, die Entwurf vor Code erzwingt
3 — Service	Service-Architekturen, Protokolle, KI-Services	Asynchrone In-Process-Pipeline (RabbitMQ + MassTransit, ADR 0002/0003) statt synchronem Microservice-Geflecht; KI-Klassifikation als erster „intelligenter Service" (ADR 0004)
4 — Persistence	Persistenzform wählen, ORM-Abstraktion	EF Core + PostgreSQL mit Repository-Abstraktion (ADR 0005); KI-Suche über pgvector auf derselben Postgres (ADR 0006)
5 — Deployment	Containerisierung, CI/CD, Observability	Compose-Stack, drei GitHub-Actions-Workflows, OpenTelemetry + Prometheus + Grafana ; Policy-ADRs 0007–0009

Das eigentliche Querschnittsthema des CAS — **KI-assistierte Software-Entwicklung** — war zugleich die Arbeitsweise der gesamten Projektarbeit. Der direkteste Transfer sind die oben beschriebenen Disziplinen: gepflegte Agent-Instructions, eigene Skills, Context-Hygiene über Datei-Artefakte und der Spec→Plan→Implement-Rhythmus.

Reflexion, Juni 2026. Erstellt mit Unterstützung von Claude (Anthropic) gemäss den FFHS-Richtlinien für KI-Einsatz in Projektarbeiten. Volltext der blockweisen KI-Nutzung: `docs/ai-usage.md` .